

Programa del curso **MC-8840**

Deep Learning

Escuela de Computación
Maestría en Ciencias de la Computación, Plan 468

I parte: Aspectos relativos al plan de estudios

1 Datos generales

Nombre del curso:	Deep Learning
Código:	MC-8840
Tipo de curso:	Teórico-práctico
Electivo o no:	Sí
Nº de créditos:	4
Nº horas de clase por semana:	3
Nº horas extracласe por semana:	9
% de las áreas curriculares:	-
Ubicación en el plan de estudios:	Curso Electivo, Bloque 3 o Bloque 4 (Normalmente Semestre 3 o 4)
Requisitos:	Ninguno
Correquisitos:	-
El curso es requisito de:	Ninguno
Asistencia:	Obligatoria.
Suficiencia:	No.
Posibilidad de reconocimiento:	No.
Vigencia del programa:	II Semestre del 2024

2 Descripción general

“By far the greatest danger of Artificial Intelligence is that people conclude too early that they understand it.”

– **Eliezer Yudkowsky**

Gracias a las mejoras en hardware y en paralelización, un grupo particular de técnicas, conocidas como aprendizaje profundo, planteadas en los años 80s, han sido implementadas actualmente y se han masificado en la academia y empresas como Google, Facebook, Amazon, y otras, para reconocer rostros, peatones (en carros que se manejan solos), reconocer patrones en texto, traducción de textos de un lenguaje a otro, detección de objetos en video, entre muchos otros usos de reconocimiento de patrones. Han logrado conectar subáreas de investigación que tradicionalmente eran excluyentes, pero que ahora bajo un mismo modelo teórico-matemático es posible unificar. El uso de aprendizaje profundo a catapultado la utilidad de la Inteligencia Artificial en nuestra vida diaria, al punto en que, sin saberlo, todos los días usamos este tipo de sistemas en nuestros celulares y demás. Cada vez que algún sistema nos recomienda una película, o cada vez que alguna red social predice qué personas aparecen en nuestras fotos, son ejemplos de cómo estas técnicas han cambiado nuestras vidas. Sus resultados se ven reflejados en áreas como la agricultura, la biología, la economía, la geología, la seguridad, la medicina, la ingeniería, entre muchas otras.

El curso de Deep Learning o Aprendizaje Profundo, presentará al estudiante conceptos relacionados con la subárea de Inteligencia Artificial más promisoría de los últimos años de una manera teórico-matemática y práctica con un enfoque ingenieril y a su vez científico (lectura y escritura de artículos). Ingenieril por que le permitirá implementar modelos de aprendizaje profundo en sistemas reales, y científica por qué proveerá las bases teóricas para expandir capas y otras estructuras matemáticas que conforman los modelos en cuestión. El curso tiene como objetivo desarrollar las habilidades necesarias para la adecuada implementación de soluciones con modelos de aprendizaje profundo diferenciables, y por tanto entrenables (su construcción se basa en datos existentes, y muchas cantidades de

ellos).

El curso pretende aportar las bases para el desarrollo de modelos y sistemas de aprendizaje profundo (sistemas con muchas capas de aprendizaje automático), para que el estudiantado se interese también en temas de investigación relacionados, en miras a sus proyectos de tesis de la maestría.

El estudiante debe tener conocimiento en álgebra lineal, cálculo y probabilidades (los cuales son cursos de bachillerato), para poder desarrollar nuevas habilidades en el desarrollo de modelos de aprendizaje profundo.

Durante el curso, el estudiante primeramente será expuesto a técnicas tradicionales (como modelos no paramétricos) que se han ido desfasando para dar paso a aprendizaje profundo, como punto de partida. Seguidamente el estudiante desarrollará habilidades de manipulación de grandes cantidades de datos, tanto imágenes como texto. Seguidamente el estudiante aprenderá cómo funcionan los modelos de aprendizaje profundo, por qué son diferenciables de punto a punto, cómo extraen características automáticamente, y por qué se dividen en capas. Se estudiarán estas capas y sus tipos con detenimiento así como su proceso particular de aprendizaje. Luego se estudiarán técnicas avanzadas para evitar *overfitting*, hacer los modelos más robustos, entre otras. Adicionalmente, el estudiante desarrollará experiencia en experimentación para optimizar los modelos haciendo cambios en los hiper-parámetros, tratando de obtener los mejores resultados de exactitud y predicción posibles. Finalmente se estudiarán herramientas que permiten implementar en código modelos de aprendizaje profundo, comprendiendo las ventajas y desventajas que cada herramienta ofrece, dado que cada una tiene su fin especial y no hay una sola que lo tenga todo.

El esquema teórico-práctico del curso permitirá desarrollar además habilidades suaves de trabajo en equipo, como por ejemplo la planificación y comunicación efectiva entre los miembros del equipo.

Adicionalmente, la lectura y escritura de artículos le dará al estudiante experiencia científica en miras de su tesis.

3 Objetivos

Objetivo general.

Adquirir las destrezas para construir un sistema de aprendizaje profundo haciendo uso de grandes cantidades de datos y de frameworks utilizados tanto de forma ingenieril como para investigación.

En la siguiente tabla se describen los objetivos específicos del curso:

Objetivo(s) del curso
Al finalizar el curso, el estudiante será capaz de:
Analizar, ordenar y manipular grandes cantidades de datos (imágenes y texto) que sirven como insumo para modelos de aprendizaje profundos
Diseñar modelos de aprendizaje profundo de manera modular, comprendiendo los diferentes tipos de capas que existen y su funcionamiento, así como el proceso de aprendizaje que sucede de punto a punto.
Comprender la base teórico-matemática detrás de los modelos de aprendizaje profundo y sus ventajas sobre modelos tradicionales.
Desarrollar experiencia planteando hipótesis y experimentando con modelos de aprendizaje profundo.
Evaluar la efectividad de un sistema de modelo de aprendizaje profundo basado en imágenes y/o texto usando una métrica cuantitativa adecuada, generalmente exactitud o precisión
Desarrollar habilidades de trabajo individual y en equipo, así como de elaboración de documentación técnica/científica, de manera colaborativa, ordenada y concisa, haciendo uso de principios y valores como responsabilidad, respeto y tolerancia.
Desarrollar habilidades de escritura y lectura de artículos científicos.

4 Contenidos

1. Repaso de algebra lineal y probabilidades
2. Introducción a Visión por Computadora
 - a) Historia - métodos pre-deep learning
 - b) Deep Learning (DL)
 - 1) Historia
 - 2) Por qué funciona? GPU + Datos (ImageNet)
 - 3) Comparación con el cerebro (corteza visual)
 - 4) Impacto en la sociedad: usos, puestos de trabajo, ética
3. Aprendizaje Supervisado: Clasificadores
 - a) Modelos no paramétricos
 - 1) K vecinos más cercanos
 - b) Modelos paramétricos
 - 1) Clasificadores y regresión lineales: Mínimos cuadrados, mínimos cuadrados regularizados y/o el perceptrón.
 - 2) Funciones de pérdida
 1. L2, L1
 2. Pérdida de Hinge
 3. Entropía cruzada
 - c) Algoritmos de optimización: Descenso de gradiente y Newton Raphson
4. Conjuntos de datos
 - a) NMIST, non-NMIST, CIFAR-10, CIFAR-100, ImageNet, PlantCLEF
 - b) Entrenamiento, validación y pruebas
 - c) Exactitud Versus Precisión
 - d) Datos desbalanceados

5. Introducción a Redes Neuronales
 - a) Funciones de activación (No linealidades)
 - 1) ReLU, Sigmoidal, Tangente hipérbolico
 - b) La neurona artificial
 - c) Retropropagación
 - d) Inicialización de pesos
 - 1) Random, Gaussian
 - 2) Repercusiones en el gradiente
 - 3) Optimización de hiper-parámetros
6. Redes Neuronales II
 - a) Actualización de parámetros
 - b) Sobre-ajuste y sub-ajuste
 - c) Regularización
 - 1) L1, L2, Lp
 - 2) Normalización por lotes
 - 3) Dropout
 - 4) Aumentado de datos
 - 5) Aprendizaje por transferencia
7. Redes Neuronales de Convolución (CNN)
 - a) Convolución y filtros
 - b) Capas de Convolución
 - c) Capas de Agrupamiento
 - d) Arquitecturas conocidas y modelos
 - 1) AlexNet, GoogleNet (Inception), ResNet, VGG, DenseNet
8. Entrenando en la Práctica
 - a) Hyper-parámetros
 - b) Uso de marcos de trabajo
 - 1) Caffe2, PyTorch, Theano, Tensorflow
9. Redes Neuronales Recurrentes (Modelando Secuencias)
 - a) Arquitectura
 - b) Problema del desvanecimiento de gradiente
 - c) Usos
 - 1) Modelos de Lenguaje (Word2Vec), traducción, generación de texto
10. Temas Avanzados

| parte: Aspectos operativos

5 Metodología de enseñanza y aprendizaje

En este curso, se plantean estrategias de aprendizaje activo, individual, social, crítico y significativo, por medio de resolución y análisis de problemas, desarrollo de proyectos de diseño y optimización, trabajo de investigación, entre otras técnicas. Los contenidos del curso serán desarrollados por medio de clases magistrales teórico-prácticas, realizadas por el profesor.

6 Evaluación

En resumen, la evaluación se desglosa según el siguiente cuadro:

Rubro	Valor (%)	Tiempo estimado entrega
Proyecto	25	Debe ser en pareja (por cantidad de estudiantes matriculados en el curso podría haber algún cambio)
Presentación de artículo científico	15	Debe ser individual
Trabajos Prácticos	60	Serán 3. Pueden ser en pareja

Dada la naturaleza práctica del curso, no se podrá optar por un examen de reposición.

7 Bibliografía

Bibliografía obligatoria:

- Ian Goodfellow, Yoshua Bengio, and Aaron Courville. 2016. Deep Learning. The MIT Press.
- Rafael C Gonzalez and Richard E Woods. Digital image processing, 2002.
- Montgomery D.C. et al., Probabilidad y estadística aplicadas a la Ingeniería, McGraw Hill, 1996
- Bishop, C., Pattern Recognition and Machine Learning,

Springer, 2006

- Chong K., Stanislaw H. An introduction to optimization, Wiley-Interscience Publication, 2001

Artículos:

- Goodfellow, I. J., Warde-Farley, D., Mirza, M., Courville, A., & Bengio, Y. (2013). Maxout Networks. *Proceedings of the 30th International Conference on Machine Learning (ICML)*, 28, 1319–1327.
- Goodfellow, I., Pouget-Abadie, J., & Mirza, M. (2014). Generative Adversarial Networks. *arXiv Preprint arXiv: ...*, 1–9. Retrieved from <http://arxiv.org/abs/1406.2661>.
- Goodfellow, I. J., Bulatov, Y., Ibarz, J., Arnoud, S., & Shet, V. (2013). Multi-digit Number Recognition from Street View Imagery using Deep Convolutional Neural Networks. *CoRR*, *abs/1312.6*, 1–13. Retrieved from <http://arxiv.org/abs/1312.6082> <http://arxiv.org/pdf/1312.6082v4.pdf>
- He, K., Zhang, X., Ren, S., & Sun, J. (2016). Delving deep into rectifiers: Surpassing human-level performance on imagenet classification. *Proceedings of the IEEE International Conference on Computer Vision, 11-18-Nov-2015*, 1026–1034. <http://doi.org/10.1109/ICCV.2015.123>
- He, K., Zhang, X., Ren, S., & Sun, J. (2015). Spatial Pyramid Pooling in Deep Convolutional Networks for Visual Recognition. *IEEE Transactions on Pattern Analysis and Machine Intelligence*, 37(9), 1904–1916. <http://doi.org/10.1109/TPAMI.2015.2389824>
- Hochreiter, S., & Jürgen Schmidhuber, J. (1997). LONG SHORT-TERM MEMORY. *Neural Computation*, 9(8), 1735–1780. Retrieved from <http://www7.informatik.tu-muenchen.de/~hochreit>
- Krizhevsky, A., Sutskever, I., & Hinton, G. E. (2012). ImageNet Classification with Deep Convolutional Neural Networks. *Advances In Neural Information Processing Systems*, 1–9. <http://doi.org/http://dx.doi.org/10.1016/j.protcy.2014.09.007>
- Long, J., Shelhamer, E., & Darrell, T. (2015). Fully convolutional networks for semantic segmentation. *Proceedings of the IEEE Computer Society Conference on Computer Vision and Pattern*

Recognition, 7-12-NaN-2015, 3431–3440.
<http://doi.org/10.1109/CVPR.2015.7298965>

- Mikolov, T., Corrado, G., Chen, K., & Dean, J. (2013). Efficient Estimation of Word Representations in Vector Space. *Proceedings of the International Conference on Learning Representations (ICLR 2013)*, 1–12. <http://doi.org/10.1162/153244303322533223>
- Nie, A., Ren, F., & Desai, N. (n.d.). ResFuse and ReFiNet: Enhanced CNN Architectures for Image Classifications.
- Reed, S., Akata, Z., Yan, X., Logeswaran, L., Schiele, B., & Lee, H. (2016). Generative Adversarial Text to Image Synthesis. *Icml*, 1060–1069.
- Szegedy, C., Liu, W., Jia, Y., Sermanet, P., Reed, S., Anguelov, D., ... Rabinovich, A. (2015). Going deeper with convolutions. *Proceedings of the IEEE Computer Society Conference on Computer Vision and Pattern Recognition, 07–12–June*, 1–9. <http://doi.org/10.1109/CVPR.2015.7298594>.
- Windows, M., Os, M., When, C. P., Wei, Y., Yildirim, P., den Bulte, C., ... Szegedy, C. (2014). Batch Normalization: Accelerating Deep Network Training by Reducing Internal Covariate Shift. *Uma Ética Para Quantos?*, XXXIII(2), 81–87. <http://doi.org/10.1007/s13398-014-0173-7.2>.
- Zeiler, M. D., & Fergus, R. (2014). Visualizing and understanding convolutional networks. *Lecture Notes in Computer Science (Including Subseries Lecture Notes in Artificial Intelligence and Lecture Notes in Bioinformatics)*, 8689 LNCS(PART 1), 818–833. http://doi.org/10.1007/978-3-319-10590-1_53.
- Yosinski, J., Clune, J., Bengio, Y., & Lipson, H. (2014). How transferable are features in deep neural networks? *Advances in Neural Information Processing Systems 27 (Proceedings of NIPS)*, 27, 1–9. Retrieved from <http://arxiv.org/abs/1411.1792>.
- Szegedy, C., Vanhoucke, V., Ioffe, S., Shlens, J., & Wojna, Z. (2016). Rethinking the Inception Architecture for Computer Vision. *Proceedings of the IEEE Computer Society Conference on Computer Vision and Pattern Recognition (CVPR)*, 2818–2826. <http://doi.org/10.1002/2014GB005021>.

- Sulc, M., & Mishkin, D. (n.d.). Very Deep Residual Networks with MaxOut for Plant Identification in the Wild.
- Long, J., Shelhamer, E., & Darrell, T. (2015). Fully convolutional networks for semantic segmentation. *Proceedings of the IEEE Computer Society Conference on Computer Vision and Pattern Recognition*, 7-12-Nov-2015, 3431–3440. <http://doi.org/10.1109/CVPR.2015.7298965>.

8. Docente

Dr. Luis Alexander Calvo Valverde.

Profesor e investigador, Instituto Tecnológico de Costa Rica

Formación académica:

- Doctor en el DOCINADE, énfasis Tecnologías Electrónicas Aplicadas.
- Universidad Estatal a Distancia. Licenciatura en Ingeniería Informática y Calidad del Software.
- Instituto Tecnológico de Costa Rica. Maestría en Gerencia de Proyectos con énfasis en Proyectos de Tecnologías de Información.
- Universidad Latina de Costa Rica. Maestría en Administración de Empresas con énfasis en Banca y Finanzas.
- Universidad Católica Anselmo Llorente y LaFuente. Bachiller en Teología. Grado Académico: Bachiller Universitario.
- Universidad Católica Anselmo Llorente y LaFuente. Bachiller en Filosofía y Humanidades. Grado Académico: Bachiller Universitario.
- Instituto Tecnológico de Costa Rica. Ingeniero en Computación con énfasis en sistemas de información. Grado Académico: Bachiller Universitario.

Últimas diez Publicaciones:

- Arias-Muñoz, A.C; Cob-García, S; Calvo-Valverde, L.A. Comparative analysis of traditional methods and a deep learning approach for multivariate imputation of missing values in the meteorological field. *Tecnología en Marcha*. Vol. 37, No 3. Julio-Setiembre, 2024. Pág. 33-47.
- Solís, M.; Calvo-Valverde, L.-A. Deep Learning for Crime Forecasting

- of Multiple Regions, Considering Spatial–Temporal Correlations between Regions. Eng. Proc. 2024, 68, 4. <https://doi.org/10.3390/engproc2024068004>
- Solís, M.; Calvo-Valverde, L.-A. Explaining When Deep Learning Models Are Better for Time Series Forecasting. Eng. Proc. 2024, 68, 1. <https://doi.org/10.3390/engproc2024068001>
 - Murillo-Fernández, M.A; Calvo-Valverde, L.A; Montero-Zeledón, E; Pérez-Hidalgo, J.E; Gutiérrez-Fallas, D.A; Gutiérrez-Araya, D. Gestión cromática en la evaluación de lesiones melanocíticas. Tecnología en Marcha. Vol. 36, No 4. Octubre-Diciembre, 2023. Pág. 107-123. <https://doi.org/10.18845/tm.v36i4.64151>
 - Calvo-Valverde, L.A; Rojas-Salazar, K; Hidalgo-Rodríguez, J.F; Mora, V; Sandoval, J.A; Bolaños-Céspedes, E; Quiros, C. A study of conversational agent solution technologies for banana farmer assistance. Tecnología en Marcha. Vol. 36, No4. Octubre-Diciembre, 2023. Pág. 3-18. <https://doi.org/10.18845/tm.v36i4.6242>
 - Maikel Mendez, Luis-Alexander Calvo-Valverde, Jorge-Andrés Hidalgo-Madriz, José-Andrés Araya-Obando. A comparison of generalized extreme value, gumbel, and log-pearson distributions for the development of intensity duration frequency curves. A case study in Costa Rica. BIO Web Conf. 62 01002 (2023) DOI: 10.1051/bioconf/20236201002
 - Solís, M.; Calvo-Valverde, L.-A. A Proposal of Transfer Learning for Monthly Macroeconomic Time Series Forecast. Eng. Proc. 2023, 39, 58. <https://doi.org/10.3390/engproc2023039058>
 - M. Solís and L.-A. Calvo-Valverde, "Performance of Deep Learning models with transfer learning for multiple-step-ahead forecasts in monthly time series", Revista Inteligencia Artificial, vol. 25, no. 70, pp. 110–125, Dec. 2022. DOI: <https://doi.org/10.4114/intartif.vol25iss70pp110-125>
 - Mendez, M.; Calvo-Valverde, L.-A.; Imbach, P.; Maathuis, B.; Hein-Grigg, D.; Hidalgo-Madriz, J.-A.; Alvarado-Gamboa, L.-F. Hydrological Response of Tropical Catchments to Climate Change as Modeled by the GR2M Model: A Case Study in Costa Rica. Sustainability 2022, 14, 16938. <https://doi.org/10.3390/su142416938>
 - Tovar-Parra, K.D.; Calvo-Valverde, L.A.; Montero-Zeledón, E.;

Murillo-Fernández, M.A.; Perez-Hidalgo, J.E.; Gutiérrez-Fallas, D.A. Automatic image segmentation using Region-Based convolutional networks for Melanoma skin cancer detection. Tecnología en Marcha. Vol. 35, special issue. IEEE Inter-national Conference on Bioinspired Processing. December, 2022. Pág. 14-25.