

## Deep Learning- Timeline

**1943:** McCulloch y Pitts proponen el primer modelo de una neurona artificial, sentando las bases para las redes neuronales.

**1958:** Frank Rosenblatt desarrolla el perceptrón, uno de los primeros modelos de redes neuronales capaces de aprendizaje.

**1965:** Ivakhnenko y Lapa introducen el aprendizaje profundo con redes neuronales multicapa, utilizando un método de optimización conocido como el método de los gradientes conjugados.

**1970s:** Paul Werbos desarrolla el algoritmo de retropropagación para entrenar redes neuronales multicapa, pero no se populariza hasta los 80s.

**1986:** Geoffrey Hinton, David Rumelhart y Ronald Williams redescubren y popularizan la retropropagación, lo que lleva a un renovado interés en las redes neuronales.

**1989:** Yann LeCun y otros utilizan redes neuronales convolucionales (CNNs) para reconocer dígitos manuscritos, demostrando su capacidad para tareas de reconocimiento de patrones.

**1990s:** Las redes neuronales comienzan a caer en desuso debido a la popularidad de otros métodos como los Support Vector Machines (SVMs), debido a problemas con el sobreajuste y la falta de datos.

**2006:** Geoffrey Hinton y sus colegas introducen el concepto de "aprendizaje profundo" y presentan una manera efectiva de preentrenar redes neuronales profundas utilizando redes de creencias profundas (DBN).

**2012:** Alex Krizhevsky, Ilya Sutskever y Geoffrey Hinton ganan el concurso ImageNet con una red neuronal convolucional profunda (AlexNet), demostrando el poder de las CNNs en el reconocimiento de imágenes.

**2014:** Se introducen redes generativas antagónicas (GANs) por Ian Goodfellow, lo que abre nuevas posibilidades en la generación de imágenes y otras tareas creativas.

**2015:** Google DeepMind presenta AlphaGo, una red neuronal profunda que vence a jugadores humanos en el juego de Go.

**2016:** ResNet, una red residual, gana el concurso ImageNet, mostrando que redes mucho más profundas pueden ser entrenadas con éxito.

**2017:** Se introduce el modelo Transformer, que revoluciona las tareas de procesamiento de lenguaje natural (NLP) y se convierte en la base de modelos como BERT y GPT.

**2018:** BERT (Bidirectional Encoder Representations from Transformers) establece nuevos récords en varias tareas de NLP.

**2020:** GPT-3, un modelo de lenguaje basado en el Transformer con 175 mil millones de parámetros, demuestra capacidades impresionantes en generación de texto.

**2023:** Modelos como DALL-E y Stable Diffusion muestran avances significativos en generación de imágenes a partir de texto.

**2023:** ChatGPT: OpenAI introduce ChatGPT, basado en GPT-4, mejorando significativamente las capacidades de generación de texto y comprensión del contexto, y mostrando un mayor nivel de coherencia y creatividad en sus respuestas (Merehead).

**2024:**

- **Aprendizaje Federado:** Gana relevancia en sectores como la salud y las finanzas al permitir el entrenamiento de modelos en dispositivos descentralizados mientras se preserva la privacidad de los datos.
- **Inteligencia Artificial Explicable (XAI):** Se vuelve crucial para generar confianza y rendición de cuentas, especialmente en aplicaciones críticas como la atención médica y los vehículos autónomos.
- **Computación Cuántica y Deep Learning:** Los avances en algoritmos y hardware cuánticos comienzan a permitir la resolución de tareas de optimización e inferencia complejas con una eficiencia sin precedentes.
- **Aprendizaje Auto-supervisado:** Mejora significativamente, permitiendo que los modelos de Deep Learning aprendan de datos no etiquetados y alcancen un rendimiento de vanguardia en diversas aplicaciones.

- Modelos Híbridos: La integración de diferentes arquitecturas de Deep Learning mejora la capacidad de los modelos para capturar dependencias espaciales y temporales en datos secuenciales.
- Vision Transformer (ViT): Se destaca en tareas de visión por computadora, permitiendo una mejor captura de las dependencias contextuales y de larga distancia en las imágenes.